

Christoph Marksches

Was bei der Bewertung von Forschungsqualität vielleicht stärker beachtet werden sollte oder Erfahrungen aus zwanzig Jahren¹

Irgendwann im Jahre 2006 lud der neue, mit vielen Erwartungen und Hoffnungen begleitete neue Berliner Wissenschaftssenator Jürgen Zöllner die Leitungen der Berliner Wissenschaftseinrichtungen zu einem Kennenlerngespräch in das Berliner Wissenschaftskolleg ein. Ich habe sehr viele Details des Gesprächs vergessen, aber an eines erinnere ich mich lebhaft. Der im Wissenschaftsmanagement sehr erfahrene Mediziner eröffnete den Präsidentinnen und Präsidenten, dass seiner Ansicht nach die Wissenschaft ein massives Qualitätsproblem habe: „Da müsst ihr was unternehmen. Und zwar dringend“. Damals erregte diese pauschale Schelte der Wissenschaft durch einen einstigen Professor für Physiologische Chemie unwillkürlich meinen Unwillen – nicht nur, weil ich eine meiner Hauptaufgaben als Herausgeber von Zeitschriften, akademischer Lehrer und damaliger Präsident der Humboldt-Universität in der Steigerung der Forschungsqualität sah, sondern auch, weil ich die allermeisten meiner Kolleginnen wie Kollegen bei dieser Aufgabe für Bündnispartner hielt und meine Einrichtung durchaus nicht für eine von massiven Problemen bei der Forschungsqualität geprägte hielt. Nun hätte es allerdings keinen guten Eindruck gemacht, seinem Senator gleich im ersten Gespräch Unwillen zu signalisieren, und so fragte ich, wenn ich mich recht erinnere, mit leicht ironischem Unterton nach, wo denn nach Ansicht Zöllners dieses massive Qualitätsproblem sichtbar werde. Es fehle, so antwortete der neue Senator, bei medizinischen und naturwissenschaftlichen Forschungen ein regulärer Test der Ergebnisse durch Replizierbarkeit und viele Ergebnisse würden sich auch gar nicht wiederholen lassen. Ganze Daten- und Abbildungsreihen seien fingiert, würden aber als authentisch weitergegeben und zitiert. Ich überlegte damals kurz, ob ich eine gerade publizierte, sehr kritische Rezension eines Heidelberger Kollegen anführen sollte, der die Kollationen der griechischen Handschriften einer Edition eines spätantiken

christlichen Textes an Mikrofichen nachkontrolliert hatte und eine bestürzende Menge von Kollationsfehlern in seiner Kritik der Ausgabe mitgeteilt hatte. Glücklicherweise unterdrückte ich auch meine Frage, ob eine solche stichprobenartige Überprüfung der Qualität in der Medizin oder den Naturwissenschaften bei Korrekturen von studentischen Arbeiten, bei der Begutachtung von Forschungsanträgen und bei der Rezension von Veröffentlichungen nicht üblich sei. Und ich vermied auch die naseweise Replik, dass wir in den historisch-philologisch arbeitenden Geisteswissenschaften solche massiven Qualitätsprobleme meines Wissens nach nicht hätten.

Plagiate

In dieser Position eines beruhigten Selbstbewusstseins erschütterten mich auch einige prominente Plagiatsfälle nicht, die während meiner Präsidentschaft unter anderem auch die Humboldt-Universität betrafen. Besonders deutlich ist mir ein Fall aus dem gleichen Jahr 2006 in Erinnerung, weil sich eine ganze Anzahl von Kollegen mit einem solchen Plagiator solidarisierten, in meinem Büro aufmarschierten und in nicht eben freundlichem Ton die Rücknahme einer Rüge verlangten, die ich öffentlich ausgesprochen hatte. Dabei war es ausgerechnet die Juristische Fakultät, an der der Abschreiber als Professor wirkte. Aber auf der anderen Seite war es ein Promovend exakt derjenigen Fakultät, der den Professor massiver, unbelegter wörtlicher Übernahmen in einem Lehrbuch überführte. In einem ebenso schwungvollen wie geistreichen Aufsatz unter dem schönen Titel „Goldene Zeiten“ rückte er nicht nur diesen Fall ins Licht der Öffentlichkeit, sondern lieferte in seinem Text mit dem von ihm geprägten Terminus „Bauernopfer-Referenz“ auch noch einen wegweisenden und bis heute oft verwendeten Beitrag zur Kategorisierung von Plagiatstypen. Der seinerzeitige Promovend ist übrigens inzwi-

¹ Erweiterte Fassung des Beitrages „Differenziert wahrnehmen. Erfahrungen zur Bewertung von Forschungsqualität“ in *Forschung & Lehre* 1/26, S. 8 – 11.

schen Professor für Bürgerliches Recht und Neuere Rechtsgeschichte an der Viadrina in Frankfurt/Oder und heißt Benjamin Lahusen.

In den Jahren meiner Präsidentschaft gerieten auch mehrere hochrangige Politikerinnen und Politiker in den Verdacht, plagiiert zu haben. Ausführliche Analysen von ohne Nachweis übernommenen Passagen wurden auf Homepages im Internet veröffentlicht und bis heute findet man auf einer dieser Seiten mehr oder minder geistreiche Attacken auf Unterstützer einer Bundesforschungsministerin, die zurücktrat, als die Philosophische Fakultät der Universität Düsseldorf ihr die Promotion aberkannte. Ich bin mir bis heute nicht sicher, ob es in diesem letzteren Fall allen verantwortlich Beteiligten wirklich nur um die Forschungsqualität einer akademischen Qualifikationsarbeit ging. Aber umgekehrt wird man schlecht bestreiten können, dass in diesen Jahren wegen dieser Plagiatsfälle auch hierzulande erste Agenturen für Qualitätssicherung entstanden, die gleichsam das von Zöllner im Wissenschaftskolleg beklagte Problem der nachträglichen Überprüfung von Forschungsdaten anzugehen versuchten, Software für die Suche nach Plagiaten zu entwickeln begannen und Vorschläge für strengere Standardvermittlung im akademischen Unterricht machten. Interessanterweise konstituierten sich stellenweise solche Agenturen in Form einer Art gemeinschaftlicher Selbsthilfe der Community, die eine nochmalige Qualitätskontrolle der nachträglichen Qualitätskontrolle übernimmt. Allerdings gab es daneben auch reichlich dubiose Formen einer kommerziellen Plagiatsjägerei, die man von der zuvor genannten Hilfe zur Kontrolle von Forschungsqualität streng unterscheiden sollte.

Nach der Feier des großen Universitätsjubiläums 2010 ging ich für zehn Jahre wieder ausschließlich in die akademische Lehre und Forschung zurück und muss bekennen, dass ich das Problem, auf das der neue Senator 2006 aufmerksam gemacht hatte, weitestgehend aus den Augen verloren habe. Im Sinne anekdotischer Evidenz kann ich allerdings darauf hinweisen, dass die eben erwähnte akademische Selbstkontrolle auch innerhalb meines Graduiertenkolloquiums weiterhin bestens funktionierte. Als einmal kurz nach meiner Resozialisierung in die Forschung ein Doktorand in einer Fußnote ohne Beleg die Definition einer „Blutrinne“ am Schwert aus einem Wikipedia-Artikel ohne Beleg in einer Fußnote aufführte, stürzten sich mehrere seiner Mitpromovenden und Promovenden geradezu auf ihn. Ich bin mir sicher, dass er das – inzwischen ist er Rektor einer

Fachhochschule – niemals wieder getan hat und tun wird.

Künstliche Intelligenz

Natürlich fiel mir aber in den letzten Jahren vor der Übernahme der Präsidentschaft der Akademie 2020 auch schon am eigenen Erleben auf, wie Künstliche Intelligenz inzwischen das Problem auch in den Geisteswissenschaften verschärft. Ich verantworte eine der großen Rezensionszeitschriften meines Faches gemeinsam mit einem Kollegium als federführender Herausgeber und frage mich natürlich seit längerem, ob manche Inhaltszusammenfassungen, die immer Teil einer guten Anzeige einer Veröffentlichung sein sollten, schon auf eine KI-Software oder noch auf eigenständige Lektüre zurückgehen. Seit einiger Zeit machen mich Bing wie Google darauf aufmerksam, dass ein Aufsatz „lang zu sein scheint“, und bieten mir eine Zusammenfassung an. Auch dahinter steckt eine mehr oder weniger gute KI. Im Blick auf die Qualität der Rezensionen bereitet mir das vermutete Phänomen allerdings noch keine großen Sorgen – mindestens so entscheidend wie die Zusammenfassung des Inhalts ist das davon noch einmal zu unterscheidende Urteil. Und ob das Urteil von einem klugen Menschen oder einer aufgrund von Wortstatistiken kombinierenden Maschine stammt, sollte man als Herausgebender in den Geisteswissenschaften erkennen können – schon allein deswegen, weil die entsprechenden KI-Tools keine solchen eigenständigen kritischen Urteile fällen können, wie wir sie in Rezensionen geistes-, kultur- und sozialwissenschaftlicher Zeitschriften lesen wollen.

Aufgrund meiner eigenen Rezensionspraxis bin ich auch nach wie vor davon überzeugt, dass ein wirklich glaubwürdiges kritisches Urteil über eine Veröffentlichung die gründliche eigenständige Lektüre voraussetzt. Es geht beim Referat nicht nur einfach um den Inhalt, sondern um Beobachtungen zur Präzision der Quellenarbeit, zur Logik und zum Stil der Argumentation und so fort. All dies stellt sich beim Referieren gleichsam automatisch ein, selbst wenn die KI irgendwann lernen sollte, so zu fragen, und vermutlich auch irgendwann entsprechend antworten kann. Im Augenblick traue ich mir zu, bei der Lektüre eines Manuskriptes zu erkennen, ob hier ein zu kritischem Urteil Befähigter den Text verfasst hat oder eine Maschine. Ob das in alle Ewigkeit so bleiben wird, weiß ich natürlich nicht. Aber ich denke dann immer an die Analogie zur Bundesdruckerei, die ihre Drucktechnik für Banknotenpapier auch verfeinern

muss, wenn wieder einmal eine kluge Fälschertruppe Banknoten so gefälscht hat, das klassische Detektoren sie nicht mehr erkennen. Es ist schließlich niemandem verboten, sich die Inhalte von Aufsätzen mit der KI zusammenfassen zu lassen – allerdings ist man nicht dazu gezwungen, Texte, die allein mit der KI generiert sind, noch durch den Abdruck in einer traditionsreichen Zeitschrift gleichsam zu adeln. Dazu müssen aber natürlich auch Herausgebende kritisch urteilen können und gute wie schlechte Qualität von Forschung identifizieren können.

Attacken auf die Forschung

Durch meine Tätigkeit in der Leitung einer Akademie der Wissenschaften habe ich seit fünf Jahren vermehrt mit den Naturwissenschaften und der Medizin zu tun. Von ihnen habe ich gelernt, was rein profitorientierte „Predatory Journals“ sind, welche ökonomischen Interessen und Mechanismen in verschiedenen Wissenschaftssystemen (wie beispielsweise dem chinesischen) hinter „Paper Mills“ von „Predatory Publishers“ stehen. Natürlich waren mir die Mechanismen des „Publish or Perish“ vertraut, aber die Ausmaße dieser absurden und qualitätsfeindlichen Form des „Auswegs“ zu mehr Veröffentlichungen habe ich schlicht unterschätzt. Zunächst konnte ich mir auch gar nicht vorstellen, dass selbst bekannte Verlage den Autorinnen und Autoren von Texten, die Herausgebende herausragender Journale abgelehnt haben, automatisch die Peer-review freie Publikation in anderen Zeitschriften des Hauses anbieten (und nicht auf der Überarbeitung in dem Sinne bestehen, die die anonymen Reviewer verlangt haben). Sie fördern also aktiv eine Art von „Journal hopping“. Noch viel erschütterter war ich allerdings, als ich begriff, dass die ersten kritischen Artikel und Blog-Beiträge über diese Phänomene relativ bald nach der von mir damals als so verwunderlich empfundenen Generalkritik des neuen Senators im Wissenschaftskolleg erschienen sind.

Wer heute, angesichts von massiver Datenmanipulation, massenhafter Verbreitung von fake science immer noch nicht wahrgenommen hat, dass wir nicht nur ein massives Qualitätsproblem haben, sondern auf diese Weise aus Teilen der Wissenschaft und von betrügerischen Pseudo-Verlagen ein veritabler „Krieg gegen die Wissenschaft“ geführt wird (so jüngst der germanistische Mediävist und Wissenschaftsmanager Peter Strohschneider), schläft offensichtlich. Besonders bitter ist allerdings, dass solche Attacken auf die Qualität der For-

schung das in verschiedenen Milieus der Gesellschaft bereits deutlich erschütterte Vertrauen in die Wissenschaft weiter reduzieren werden, jedenfalls dann, wenn nichts unternommen wird.

Nationale und internationale Initiativen zur Schärfung von Forschungsstandards

Natürlich wird schon eine ganze Menge unternommen. Schon 2012 wurde auf einem Treffen der American Society for Cell Biology die „San Francisco Declaration on Research Assessment“ (DORA) initiiert, eine Initiative zur Steigerung von qualitativen Elementen der Bewertung von Forschungsergebnissen und zur Kritik der rein quantitativen Messungen beispielsweise von Impact-Faktoren. Für eine Revision von entsprechenden Kinderkrankheiten bibliometrischer Verfahren hat sich 2015 das „Leiden Manifesto for Research Metrics“ ausgesprochen. Die europäische Vereinigung der Wissenschaftsakademien, ALLEA, hat 2017 einen 2023 noch einmal revidierten „European Code of Conduct for Research Integrity“ mit den vier Prinzipien Reliability, Honesty, Respect und Accountability veröffentlicht. Im selben Jahr wurde in Berlin durch den Neurologen Ulrich Dirnagl das „QUEST Center for Responsible Research“ am Berlin Institute of Health (BIH) der Charité gegründet, das zunächst einmal durch seine Forschungen die biomedizinische Forschung am BIH vertrauenswürdiger, nützlicher und ethischer gestalten will, aber darüber hinaus auch die ganze Disziplin entsprechend beeinflussen möchte. Eine ganze Reihe von deutschen Forschungseinrichtungen und Institutionen sind inzwischen Mitglied der 2022 gegründeten europäischen „Coalition for Advancing Research Assessment“ (CoARA) und haben das in diesem Jahr publizierte „Agreement on Reforming Research Assessment“ unterschrieben. In diesem Text sind zehn Commitments formuliert, mit denen die Bewertung von Forschungsqualität verbessert werden soll. Vor allem soll auch hier vermieden werden, den offenkundigen Problemen eines Systems, das die riesige Menge von teils KI-generierten Manuskripten, Projektanträgen und Bewerbungen kaum mehr mit klassischen Methoden bewältigen kann, durch rein quantifizierende Verfahren wie Publikationszahlen, Zitationsraten oder Rankings zu begegnen. CoARA ist wie DORA eine Verabredung, mehr Ideen und Inhalte kritisch zu beurteilen und die unterschiedlichen Typen wissenschaftlicher Aktivität und die verschiedenen fachlichen Ausprägungen von Wissenschaft und Veröffentli-

chungsformen stärker in den Blick zu nehmen. Seit 2024 gibt es auf Initiative der Deutschen Forschungsgemeinschaft ein „National Chapter“, einen deutschen Landesverband, der sich, wie mir scheint, kritisch und konstruktiv in die allgemeinen CoARA-Diskussionen einbringt und versucht, nationale wie europäische Standards zu schärfen, ohne in die Falle einer weiteren Bürokratisierung und zeitfressenden Überregulierung zu laufen. Zu dieser Gruppe sind auch alle die Institutionen und Verbünde als assoziierte Mitglieder eingeladen, die sich aus unterschiedlichen Gründen schwertun, CoARA beizutreten und das erwähnte Agreement zu unterzeichnen.

Drei Vorschläge zur Qualitätssicherung

Entscheidend angesichts der schon von Zöllner 2006 konstatierten Qualitätsprobleme, die sich durch die von Strohschneider so präzise auf den Begriff gebrachte Kriegsführung in einzelnen Fächern noch einmal verschärft haben, sind aus meiner Sicht drei Dinge:

KI in der akademischen Ausbildung

Wir müssen erstens bereits in der akademischen Ausbildung auf der einen Seite zu einem sachgerechten Umgang mit KI-Tools anhalten, aber auch kritische Urteilskraft und ein strenges Bewusstsein für Forschungsqualität vermitteln. Ich wünsche mir schon von meinen Studierenden die Fähigkeit zum kritischen Urteil und möchte in der Wissenschaft Menschen zu kritischer Urteilskraft befähigen. Denn auf kritischer Urteilskraft ruht alle Forschungsqualität auf und auch alle Bewertung von Forschungsqualität, die mehr ist als Statistik. Vorschläge für wissenschaftsethische Trainingsprogramme, wie sie beispielsweise die von der Europäischen Union finanzierte und vom „Deutschen Referenzzentrum für Ethik in den Biowissenschaften“ der Bonner Universität lancierte Initiative „Improving Research Ethics Expertise and Competencies to Ensure Reliability and Trust in Science“ (IRECS) oder das oben erwähnte Berliner „QUEST Center for Responsible Research“ vorgelegt haben, müssen um diese Dimension der Schulung der Urteilskraft und entsprechende Programme ergänzt werden. Zu einer solchen Ausbildung gehört, dass wir die Implementierung neuer Zitierstandards brauchen, die die Verwendung von KI-Tools bei der wissenschaftlichen Arbeit wie bei ihrer Begutachtung präzise offenlegen. Hier dürfen die immer präziser gewordenen Standards bei der Kennzeichnung von Übernahmen fremder wissenschaftlicher

Ergebnisse nicht weiter unterboten werden, wenn Missbrauch überhaupt sanktionierbar sein soll.

Qualitätsbewusste Forschungsbewertung

Zweitens ist es dringend notwendig, bestimmte Phänomene des „Overkill“ und unsinniger Therapien im Wissenschaftssystem weiter entschlossen abzubauen und das System insgesamt an dieser Stelle zu entschleunigen: An vielen Stellen werden, wie wir sahen, Pseudo-Marker für Qualität wie Zitationshäufigkeiten und Veröffentlichungsmengen schon sehr kritisch gesehen. Nun muss man aber zusätzlich aufpassen, dass die neuen Forderungen nach Wirkung, Transfer und Gemeinwohl-Orientierung von Forschung, die inzwischen landauf, landab und mit Recht erhoben werden, nicht neue Quantifizierungen ins System bringen. Ob es wirklich sinnvoll ist, wegen der schwarzen Schafe der Predatory Publishers gleich alle Verlage zu bekämpfen, wie zuletzt Bernhard A. Sabel und Dan Larhammar in ihrer, in „Royal Society Open Science“ veröffentlichten „Stockholm Declaration“ 2025 wieder einmal vorgeschlagen haben, darf man doch mit Fug und Recht bezweifeln. Verlage könnten doch gerade Bündnispartner einer qualitätsbewussten Forschungsbewertung sein. Schließlich wird in einem guten Wissenschaftssystem durch eine angemessene Grundfinanzierung auch trial and error als Grundmethodik von Wissenschaft finanziert und nicht nur quasi ausschließlich über Drittmittel das, was gerade kein Irrtum, sondern exzellente Forschung zu sein scheint.

Kritik der digitalen Vernunft

Drittens wird aber noch viel mehr wissenschaftstheoretische Reflexion im System gebraucht. Hätte ich beispielsweise schon 2006 gesehen, wie unterschiedlich gut in bestimmten Natur- und Geisteswissenschaften die nachträgliche Überprüfbarkeit von Daten möglich ist, wie sehr sich überhaupt Disziplinen im Blick auf die Forschungs- und Veröffentlichungspraktiken unterscheiden, hätte ich mit meiner eigenen geisteswissenschaftlichen Fachfahrung nicht Beobachtungen eines Mediziners zu neutralisieren versucht. Wir arbeiten an dieser Stelle noch viel zu oft mit der anekdotischen, auf der eigenen begrenzten Wissenschaftsbiographie beruhenden Evidenz, nicht aber mit präzisen Bildern unterschiedlicher Wissenschaftskulturen und disziplinärer Verfasstheiten. Wenn man präziser bestimmen will, wo KI-Tools Forschungsqualität steigern können und wo

ihre Anwendung langfristig die kritische Urteilskraft beschädigt, braucht es eine entsprechend differenzierte „Kritik der digitalen Vernunft“. Hier muss die Frage diskutiert werden, wie in Zukunft eine Künstliche Intelligenz und eine menschliche Intelligenz bei der Forschung und bei der Beurteilung ihrer Qualität so zusammenarbeiten können, dass Qualität von Forschung und Vertrauen in diese Qualität nicht in massiven Problemen stecken bleiben. Dazu ist aber notwendig, dass diese Probleme überhaupt erst einmal überall differenziert wahrgenommen werden.

Dr. Dr. h.c. mult. Christoph Marschies ist Professor für Antikes Christentum an der Humboldt-Universität zu Berlin und Präsident der Berlin-Brandenburgischen Akademie der Wissenschaften

